

Concesión de crédito con IA explicable

Guía completa de la práctica B4-T2 (XAI)

Construcción, optimización y auditoría de un modelo de scoring bajo dos escenarios de coste

Qué es este documento

Una explicación de principio a fin de todo lo que se ha hecho en la práctica: qué problema se resuelve, qué métodos se han usado, por qué se eligió cada uno, qué resultados dan y —sobre todo— **cómo interpretarlos**.

Está escrito asumiendo que el lector **no tiene base previa en explicabilidad (XAI)**: cada técnica se introduce desde cero, con la intuición primero y el detalle técnico después. El objetivo es que cualquier miembro del grupo pueda entender y defender el trabajo completo.

Índice

Parte	Contenido	Qué responde
1	El problema y los dos escenarios de coste	Qué nos piden exactamente
2	Los datos y las decisiones de limpieza	Qué había y qué hicimos con ello
3	El modelo: de los árboles al Gradient Boosting	Cómo predice
4	Cómo se mide si el modelo es bueno	AUC, calibración, lift
5	De probabilidad a decisión: el umbral por coste	Dónde se corta y por qué
6	XAI: explicar el modelo (parte central)	Surrogado, SHAP, contrafactuales, ALE, LIME
7	El enfoque alternativo: Multiarmed Bandit	Aprendizaje por refuerzo
8	Las extensiones y mejoras	Cómo se bajó el coste y se reforzó el análisis
9	Resultados: tabla por tabla, cómo leerlos	Qué significa cada número
10	Límites, ética y crítica	Qué no hace bien y por qué
11	Preguntas de defensa y respuestas	Cómo responder al tribunal
12	Glosario	Cada término en una línea

Cómo leer esta guía

Las partes 1 a 5 explican el **modelo**; la parte 6 explica la **explicabilidad**, que es el núcleo de la asignatura; las partes 7 y 8 cubren las alternativas y mejoras. Si se dispone de poco tiempo, lo imprescindible es: la **parte 5** (el umbral es lo que determina la nota de resultados), la **parte 6** (es lo que se evalúa como análisis) y la **parte 11** (defensa).

Parte 1. El problema y los dos escenarios de coste

1.1 Qué se pide

Se dispone de un histórico de clientes de crédito (fichero **cs_construccion.csv**, unas 105.000 personas) del que se sabe si cada uno acabó teniendo un **impago grave** en los dos años siguientes. La variable que recoge ese hecho se llama **SeriousDlqin2yrs** y vale 1 si hubo impago grave y 0 si no.

Con ese histórico hay que construir un modelo que decida, para cada uno de los **45.000 clientes nuevos** del fichero **cs_produccion.csv**, si se le concede o se le deniega el crédito. Y hay que hacerlo **dos veces**, bajo dos supuestos de coste distintos, entregando un fichero de predicciones por cada uno.

1.2 La convención de decisión: qué significa 'positivo'

Este punto genera confusión constantemente, así que conviene fijarlo de entrada. En la práctica se ha adoptado la convención de que la clase positiva (1) es **el impago**:

Predicción del modelo	Interpretación	Decisión de negocio
1 (positivo)	Se estima que el cliente impagará	Se deniega el crédito
0 (negativo)	Se estima que el cliente pagará	Se concede el crédito

De ahí se deducen los dos tipos de error, que son el centro de toda la práctica:

Error	Qué ha pasado	Qué cuesta
Falso positivo (FP)	Se deniega el crédito a alguien que habría pagado	Coste de oportunidad: se pierde un buen cliente y su margen
Falso negativo (FN)	Se concede el crédito a alguien que impaga	Coste directo: se pierde el capital prestado

1.3 Los dos escenarios

Escenario	Coste FP	Coste FN	Lectura	Fichero de entrega
1	1	1	Los dos errores cuestan igual	cs_produccion1.csv
2	1	10	Un impago cuesta como 10 denegaciones injustas	cs_produccion2.csv

El escenario 2 es el realista en banca: perder el capital de un préstamo duele mucho más que perder el margen de un cliente. Y cambia por completo la política óptima: si cada impago cuesta diez veces más, compensa denegar a mucha más gente con tal de no dejar pasar impagos.

La idea más importante de toda la práctica

El modelo **no decide**: solo calcula una **probabilidad de impago** para cada cliente. La decisión de conceder o denegar se toma después, comparando esa probabilidad con un **umbral**. Y ese umbral depende de los costes.

Consecuencia práctica: **un mismo modelo sirve para los dos escenarios**. No hace falta reentrenar nada; basta con cambiar el punto de corte. Modelo y decisión son piezas separables. Si solo se retiene una frase de esta guía, que sea esta.

Parte 2. Los datos y las decisiones de limpieza

2.1 Las variables

Variable	Qué mide
RevolvingUtilizationOfUnsecuredLines	Porcentaje del límite de tarjetas y líneas de crédito que el cliente tiene consumido
age	Edad en años
NumberOfTime30-59DaysPastDueNotWorse	Veces que se ha retrasado entre 30 y 59 días (últimos 2 años)
NumberOfTime60-89DaysPastDueNotWorse	Veces que se ha retrasado entre 60 y 89 días
NumberOfTimes90DaysLate	Veces que se ha retrasado 90 días o más (el más grave)
DebtRatio	Proporción de los ingresos que se va en pagar deudas
MonthlyIncome	Ingreso mensual
NumberOfOpenCreditLinesAndLoans	Número de préstamos y líneas de crédito abiertas
NumberRealEstateLoansOrLines	Número de préstamos hipotecarios
NumberOfDependents	Personas a cargo

2.2 Los cuatro problemas de calidad que se encontraron

- 1 **Faltan ingresos en el 20% de los clientes.** Casi uno de cada cinco no tiene informado MonthlyIncome. Es muchísimo como para ignorarlo.
- 2 **Códigos 96 y 98 en las variables de retrasos.** Aparecen siempre en las tres variables a la vez, lo que delata que no son recuentos reales (nadie se retrasa 96 veces) sino **códigos administrativos** que significan algo como 'situación especial'.
- 3 **Colas absurdas.** RevolvingUtilization y DebtRatio son ratios que deberían moverse entre 0 y 1, pero alcanzan valores de miles. Son errores de registro, agravados porque DebtRatio se calcula dividiendo por el ingreso, y cuando el ingreso falta el cociente se descontrola.
- 4 **Edades de 0 años.** Imposible en un solicitante de crédito.

2.3 Qué se hizo con cada problema, y por qué

Antes de las decisiones concretas, hay una **restricción que lo condiciona todo**: en producción hay que emitir una decisión para los 45.000 clientes, sin excepción. Por tanto **ninguna limpieza puede eliminar filas**. Un modelo que se entrenase solo con los clientes 'cómodos' y luego tuviera que puntuar a todos estaría haciendo trampa consigo mismo.

Problema	Decisión tomada	Por qué
Ingresos ausentes (20%)	No se imputan ni se descartan. Se crea una variable indicadora <i>IngresoAusente</i> y se dejan los huecos tal cual	Se comprobó que la ausencia lleva información : los clientes sin ingreso informado impagan menos (5,5% frente a 7,0%). Es un resultado contraintuitivo que demuestra que el dato no falta al azar. Rellenarlo con la media destruiría esa señal
Códigos 96/98	Se sustituyen por un tope de 20 y se marca la variable <i>CodigoMoraEspecial</i>	Esos clientes tienen una tasa de impago del 54% frente al 6,7% general: el código es enormemente informativo. Se conserva la señal sin dejar que un 98 distorsione la escala numérica
Colas extremas	Capado (winsorización) al percentil 99 , con los topes calculados solo con datos de construcción y reutilizados en producción	Calcular los topes con producción sería fuga de información . A los árboles apenas les afecta, pero estabiliza los gráficos, el análisis SHAP y el modelo lineal de referencia
Edad 0	Se eliminan esas filas, pero solo en construcción	Son errores puros y son poquísimas. En producción no se puede eliminar a nadie

Por qué toda la limpieza está en una sola función

Toda la limpieza se encapsuló en una función *limpiar()* que se aplica **igual** a construcción y a producción. Es una decisión de diseño deliberada: cualquier diferencia entre lo que el modelo ve al entrenar y lo que ve al predecir invalidaría la estimación del coste. Es el error clásico en proyectos de datos y así queda estructuralmente impedido.

2.4 ¿Se parecen construcción y producción? El PSI

Antes de fiarse de que el coste medido en validación se va a repetir en producción, hay que comprobar que ambos ficheros describen a **la misma población**. Si los clientes de producción fueran distintos (por ejemplo, más jóvenes o más endeudados), el modelo llegaría descolocado.

Para medirlo se usa el **PSI (Population Stability Index)**, el indicador estándar en banca. Se parte cada variable en tramos y se compara qué porcentaje de clientes cae en cada tramo en un fichero y en el otro. Interpretación convencional:

Valor del PSI	Interpretación
Menor que 0,10	Población estable: no hay problema
Entre 0,10 y 0,25	Cambio moderado: conviene vigilar
Mayor que 0,25	Cambio severo: hay que replantear el modelo

Resultado obtenido: PSI del orden de 0,0005 en todas las variables, es decir, unas 200 veces por debajo del umbral de alarma. Construcción y producción son la misma población, y por tanto el coste estimado en validación es directamente extrapolable a producción. Es un resultado que conviene mencionar en la defensa porque legitima todo lo demás.

Parte 3. El modelo: de los árboles al Gradient Boosting

3.1 Un árbol de decisión, en una página

Un árbol de decisión es una cadena de preguntas de sí/no. Por ejemplo: '¿la utilización del crédito supera el 60%?'. Si la respuesta es sí, se pasa a otra pregunta; si es no, a otra distinta. Al final de cada camino hay una hoja con una estimación (aquí, una probabilidad de impago).

Su gran virtud es que **se lee como un conjunto de reglas**, lo que lo hace transparente por naturaleza. Su gran defecto es que un árbol suficientemente profundo **memoriza** los datos de entrenamiento en vez de aprender patrones generales, y entonces falla con clientes nuevos.

3.2 Gradient Boosting: muchos árboles malos que suman uno bueno

La idea del **boosting** es no construir un árbol grande, sino **muchos árboles pequeños encadenados**, donde cada uno se dedica a corregir los errores que cometió la suma de los anteriores:

- 1 Se entrena un primer árbol pequeño. Predice regular.
- 2 Se calculan los **errores** que ha cometido sobre cada cliente.
- 3 Se entrena un segundo árbol cuyo objetivo es **predecir esos errores**.
- 4 Se suma al primero. El conjunto ya predice algo mejor.
- 5 Se repite el proceso cientos de veces.

El resultado es un modelo muy preciso, construido a base de correcciones sucesivas. La contrapartida es que deja de ser legible: nadie puede leer 300 árboles encadenados y entender la lógica. **Ese es exactamente el motivo por el que después hace falta toda la parte de explicabilidad**: el modelo se ha vuelto una caja negra, y en concesión de crédito no se puede aceptar una caja negra sin auditar.

3.3 Por qué se eligió HistGradientBoostingClassifier

- **Es el estado del arte en datos tabulares** de este tamaño. En tablas (a diferencia de imágenes o texto), el boosting de árboles gana sistemáticamente a las redes neuronales.
- **Gestiona los valores ausentes de forma nativa**. Esta es la razón decisiva. En lugar de exigir que se rellenen los huecos, el modelo **aprende** hacia qué rama conviene enviar a los clientes con dato ausente. Como se demostró que la ausencia de ingreso es informativa, esto es justo lo que se necesitaba: se aprovecha la señal en vez de destruirla.
- **Entrena rápido** sobre 100.000 filas, porque agrupa los valores en histogramas en lugar de evaluar todos los cortes posibles.

3.4 El modelo de referencia: regresión logística

Antes del modelo complejo se entrenó una **regresión logística**, que es un modelo lineal simple y totalmente interpretable. No se hizo por trámite: sirve de **listón mínimo**. Si el Gradient Boosting no batiera con claridad a la logística, no habría ninguna justificación para asumir su opacidad.

Resultado: la logística alcanza un AUC de **0,854** y el Gradient Boosting **0,870**. La mejora justifica la elección, y de paso el argumento queda documentado por si en la defensa preguntan '¿por qué no algo más sencillo?'.

3.5 Cómo se ajustaron los hiperparámetros

Los hiperparámetros (ritmo de aprendizaje, profundidad, número de hojas, regularización) se ajustaron con **búsqueda aleatoria y validación cruzada de 3 particiones**, optimizando el AUC. Se usó búsqueda

aleatoria en lugar de probar todas las combinaciones porque con el mismo presupuesto de cómputo explora mejor el espacio.

Se optimizó el **AUC** y no directamente el coste por un motivo importante: el AUC mide la capacidad de **ordenar** a los clientes por riesgo, y esa capacidad es **independiente del umbral**. Primero se consigue el mejor ordenador de riesgo posible; después, y por separado, se elige dónde cortar en función de los costes de cada escenario.

Parte 4. Cómo se mide si el modelo es bueno

4.1 Por qué la 'accuracy' no vale aquí

Solo un **6,7%** de los clientes acaba en impago. Un modelo que concediera crédito a absolutamente todo el mundo acertaría el **93,3%** de las veces y sería completamente inútil: no detectaría ni un solo impago. Por eso la exactitud se descarta desde el principio y se usan métricas pensadas para **clases desbalanceadas**.

4.2 AUC: la capacidad de ordenar

El **AUC** responde a una pregunta muy concreta: si se toma al azar un cliente que impagó y otro que pagó, ¿con qué probabilidad el modelo le asigna más riesgo al que impagó? Un 0,5 es azar puro y un 1,0 es perfección.

El modelo obtiene **AUC = 0,870**: en el 87% de esas parejas ordena correctamente. Es un buen resultado para scoring de crédito, donde valores entre 0,80 y 0,87 son lo habitual en la industria.

4.3 Precision-Recall y AP

La curva Precision-Recall se centra en la clase minoritaria (los impagos), que es la que interesa, y por eso es más exigente que la ROC con datos desbalanceados. Dos conceptos que conviene no confundir:

- **Recall** (o sensibilidad): de todos los impagos que realmente hubo, qué porcentaje detectó el modelo. Es lo que importa en el escenario 2.
- **Precisión**: de todos los clientes a los que el modelo denegó, qué porcentaje iba a impagar de verdad. Mide cuánto se molesta a clientes buenos.

Hay una tensión inevitable entre ambas: subir el recall (detectar más impagos) obliga a denegar más y por tanto baja la precisión. Dónde situarse en esa tensión es, precisamente, lo que decide el umbral.

4.4 Calibración: la métrica de la que depende todo lo demás

Un modelo está **bien calibrado** cuando sus probabilidades significan lo que dicen: entre los clientes a los que asigna un 30% de riesgo, debe impagar aproximadamente el 30%.

Por qué la calibración es crítica en esta práctica

Todo el cálculo del umbral óptimo por coste **parte de suponer que las probabilidades son fiables**. Si el modelo dijera '10%' y en realidad impagara el 25%, la fórmula del umbral daría un valor equivocado y la decisión sería sistemáticamente mala.

Se comprobó con la **curva de calibración**: se agrupan los clientes por probabilidad predicha y se compara con la tasa real de impago de cada grupo. Los puntos caen prácticamente sobre la diagonal, así que las probabilidades son fiables y **se puede optimizar el umbral con confianza**. Esto es lo que explica que el umbral teórico y el empírico casi coincidan (ver parte 5).

4.5 Lift y captura por deciles

Es el formato en que se presenta un modelo de riesgo al negocio. Se ordenan los clientes por riesgo y se parten en diez grupos (deciles):

- **Lift**: cuántas veces más impagos hay en un decil respecto a la media. Un lift de 5 en el primer decil significa que ahí se concentran cinco veces más impagos de lo normal.
- **Curva de captura**: qué porcentaje del total de impagos se acumula en los deciles de más riesgo.

El resultado confirma que el modelo ordena bien: los primeros deciles concentran la mayor parte de los impagos, lo que significa que **denegando a una fracción pequeña de solicitantes se elimina una parte grande de las pérdidas**. Es exactamente lo que se le quiere poder decir a un comité de riesgos.

Parte 5. De probabilidad a decisión: el umbral por coste

5.1 La fórmula del umbral óptimo

El modelo entrega una probabilidad de impago p . Hay que decidir a partir de qué valor de p se deniega. La teoría de la decisión lo resuelve comparando el coste esperado de cada opción:

Coste esperado de CONCEDER = $p \times \text{coste_FN}$ (si impaga, se pierde el capital)
Coste esperado de DENEGAR = $(1 - p) \times \text{coste_FP}$ (si habría pagado, se pierde el cliente)
Conviene denegar cuando: $p \times \text{coste_FN} > (1 - p) \times \text{coste_FP}$
Despejando: $p > \text{coste_FP} / (\text{coste_FP} + \text{coste_FN})$

Aplicando la fórmula a cada escenario:

Escenario	Cálculo	Umbral teórico	Umbral empírico obtenido	Lectura
1 (FP=1, FN=1)	$1 / (1+1)$	0,500	0,545	Se deniega solo a quien es más probable que impague que que pague
2 (FP=1, FN=10)	$1 / (1+10)$	0,091	0,090	Basta un 9% de riesgo para denegar: se es mucho más conservador

Por qué la coincidencia entre teórico y empírico es un gran resultado

El umbral teórico sale de una fórmula que **supone probabilidades perfectamente calibradas**. El empírico sale de probar 199 umbrales sobre los datos de validación y quedarse con el más barato.

Que en el escenario 2 den **0,091 y 0,090** no es casualidad: **demuestra que el modelo está muy bien calibrado**. Y además da tranquilidad en los dos sentidos: la teoría confirma que el valor empírico no es un capricho de la muestra de validación, y el dato empírico confirma que la teoría es aplicable. Es uno de los puntos fuertes de la práctica y conviene sacarlo en la defensa.

5.2 Qué implica cada umbral en la práctica

Escenario	Umbral	% denegados	Coste medio por cliente	Comportamiento
1 (FP=FN=1)	0,545	1,76%	0,062	Muy permisivo: solo se deniega a los casi seguros impagos
2 (FP=1, FN=10)	0,090	18,9%	0,331	Conservador: se deniega a casi 1 de cada 5, aceptando molestar a buenos clientes con tal de frenar impagos

Obsérvese que el coste del escenario 2 (0,331) es mucho mayor que el del 1 (0,062). Esto **no** significa que el modelo funcione peor: significa que el escenario 2 **penaliza más**. Son dos escalas distintas y no son comparables entre sí. Solo tiene sentido comparar dentro de un mismo escenario.

5.3 La forma de la curva de coste

La curva del escenario 2 es **muy empinada a la izquierda del óptimo y bastante plana a la derecha**. Traducido: quedarse corto denegando sale carísimo, mientras que pasarse un poco denegando sale relativamente barato. Ante la duda, en el escenario 2 conviene errar por el lado conservador.

En el escenario 1, en cambio, el mínimo es plano en toda su vecindad: da bastante igual usar 0,50 que 0,55, porque los errores cuestan lo mismo y hay pocos clientes en esa zona de probabilidad.

Parte 6. XAI: explicar el modelo

Qué es la XAI y por qué es obligatoria aquí

XAI (eXplainable Artificial Intelligence) es el conjunto de técnicas que permiten entender por qué un modelo opaco toma las decisiones que toma.

En concesión de crédito no es un lujo académico, sino una **necesidad legal y comercial**: la normativa europea reconoce el derecho a obtener una explicación de las decisiones automatizadas que afectan a las personas, y un banco tiene que poder demostrar que no discrimina y poder decirle a un cliente por qué se le ha denegado. Un modelo que acierte mucho pero no pueda explicarse **no es desplegable**.

6.1 Dos distinciones que hay que tener claras

Distinción	Significado	En esta práctica
Interpretable vs Explicable	Un modelo <i>interpretable</i> se entiende por su propia estructura (un árbol pequeño, una regresión). Un modelo <i>explicable</i> es opaco pero se le aplican técnicas externas para entenderlo	El Gradient Boosting es opaco: se le aplican técnicas de explicación por fuera
Global vs Local	Una explicación <i>global</i> describe cómo se comporta el modelo en conjunto. Una <i>local</i> explica una única predicción concreta	Global: surrogado, SHAP global, permutación, PDP, ALE. Local: SHAP local, contrafactuales, LIME

La auditoría usa las dos: la global sirve para **validar la política** ante un comité de riesgos o un regulador; la local sirve para **responder a un cliente concreto** que pregunta por su caso.

6.2 Técnica 1: el modelo surrogado

Qué es

Se entrena un **árbol de decisión pequeño** (profundidad 3) cuyo objetivo **no es predecir la realidad**, sino **imitar lo que decide el Gradient Boosting**. Es un 'gemelo simplificado': una traducción del modelo opaco a un puñado de reglas legibles.

La métrica clave: la fidelidad

La **fidelidad** es el porcentaje de decisiones del modelo original que el árbol simplificado reproduce. Es fundamental entender que **no mide acierto sobre la realidad, sino parecido con el modelo**. Una fidelidad baja significaría que las reglas no representan al modelo y que no se pueden usar para explicarlo.

Resultados: 94% de fidelidad en el escenario 2 y 99% en el escenario 1. Es decir, unas pocas reglas simples reproducen casi toda la política del modelo, de modo que sí sirven como resumen honesto.

Cómo se lee

Cada camino desde la raíz hasta una hoja es una regla del tipo 'si la utilización del crédito supera X y hay más de Y retrasos, entonces se deniega'. Es el formato que se llevaría a un comité de riesgos o a documentación regulatoria.

6.3 Técnica 2: SHAP (la más importante)

La intuición: repartir el mérito de forma justa

SHAP viene de la **teoría de juegos cooperativos** y de los **valores de Shapley**, que resuelven un problema clásico: si un equipo consigue un resultado trabajando junto, ¿cuánto le corresponde a cada

miembro?

La analogía se traslada directamente: la 'ganancia' es la diferencia entre la probabilidad que el modelo asigna a este cliente y la probabilidad media de la población, y los 'jugadores' son las variables. SHAP reparte esa diferencia entre las variables de forma **matemáticamente justa**, evaluando cuánto aporta cada una en todas las combinaciones posibles con las demás.

Por qué SHAP es el estándar

Los valores de Shapley son la **única** forma de repartir que cumple simultáneamente un conjunto de propiedades deseables, entre ellas que **las contribuciones sumen exactamente la predicción** (eficiencia), que una variable que no influye reciba cero, y que si una variable aporta más que otra en todos los casos, reciba más.

Esa garantía teórica es lo que lo distingue de métodos heurísticos, y por eso es el estándar de la industria. Además, para modelos de árboles existe *TreeSHAP*, que lo calcula de forma exacta y rápida en lugar de aproximarlos.

SHAP global: el gráfico beeswarm

Es el gráfico que parece un enjambre de puntos. Se lee así:

- **Cada punto es un cliente**, y hay una fila por variable.
- **La posición horizontal** indica cuánto y hacia dónde empujó esa variable la predicción de ese cliente: a la derecha, hacia el impago; a la izquierda, hacia el pago.
- **El color** indica si el valor de la variable era alto (rojo) o bajo (azul) para ese cliente.
- **El orden vertical** es de mayor a menor importancia global.

Cómo interpretar el resultado obtenido: en las filas superiores aparecen la utilización de las líneas de crédito y los contadores de morosidad, con los puntos rojos (valores altos) claramente a la derecha. Traducción: **tener las tarjetas al límite y acumular retrasos empuja con fuerza hacia la denegación**. En la edad ocurre lo contrario: los valores altos (rojo) caen a la izquierda, es decir, ser mayor empuja hacia la concesión.

SHAP local: el gráfico waterfall

Explica **un cliente concreto**. Parte del valor base (la probabilidad media de la población) y va sumando la contribución de cada variable —unas empujan hacia arriba, otras hacia abajo— hasta llegar a la probabilidad final de ese cliente. Es literalmente la **descomposición de su decisión**, y es la base de la explicación que se le daría.

En la práctica se explicaron tres perfiles deliberadamente distintos: una denegación clarísima, una **denegación justo en el borde del umbral** (el caso más delicado de justificar, porque una variación mínima habría cambiado la decisión) y una concesión clara.

6.4 Técnica 3: contrafactuales

Qué son

Un contrafactual responde a la pregunta que de verdad le interesa a un cliente denegado: no tanto '¿por qué?' como '**¿qué tendría que cambiar para que me lo concedieran?**'. Técnicamente es la modificación **más pequeña posible** de los datos del cliente que hace que el modelo cambie de decisión.

Se generaron con la librería **DiCE**, pero con dos restricciones añadidas que son la parte interesante del trabajo, porque DiCE por sí solo no las aplica:

- 1 **Accionabilidad.** Solo se permite variar variables sobre las que el cliente puede actuar: utilización del crédito, ratio de deuda, ingreso y número de líneas abiertas. No tendría ningún sentido recomendar 'tenga 20 años más', ni se puede reescribir el historial de impagos.
- 2 **Plausibilidad.** Los cambios deben ir en la dirección realista y con magnitud razonable: la deuda y la utilización solo pueden **bajar**, y el ingreso solo puede **subir de forma moderada** (hasta un 30%). Sin esta restricción el generador propone cambios matemáticamente válidos pero absurdos como recomendación, del tipo 'triplique su sueldo'.

Además, cada candidato se **verifica contra el modelo real** y solo se acepta si deja la probabilidad por debajo del **umbral real de la política**, no del 0,5 genérico. Y cuando ningún cambio accionable revierte la denegación —lo que ocurre con los perfiles de morosidad grave— **el sistema lo hace constar explícitamente** en lugar de inventar recomendaciones vacías. Esa honestidad es preferible a dar falsas esperanzas.

6.5 Técnicas 4 y 5: importancia por permutación y PDP

Se usaron como **contraste independiente** de SHAP, para comprobar que las conclusiones no eran un artefacto de una sola técnica.

- **Importancia por permutación:** se barajan al azar los valores de una variable y se mide cuánto empeora el AUC. Si al destruir una variable el modelo se hunde, esa variable era importante. Su ventaja es que mide la importancia **real sobre datos no vistos**.
- **Dependencia parcial (PDP):** muestra el efecto medio de una variable sobre la probabilidad predicha, recorriendo todo su rango. No dice solo *cuánto* importa una variable, sino **qué forma** tiene su efecto.

El resultado revela **efectos claramente no lineales, de tipo escalón**: superar cierto nivel de utilización o registrar el primer retraso grave cambia la contribución de golpe. Esto es justamente lo que un modelo lineal no puede capturar, y explica de forma visual por qué el boosting bate a la regresión logística.

6.6 Técnica 6: ALE, la corrección de la PDP

La PDP tiene un **defecto conocido** cuando las variables están correlacionadas, y aquí lo están (los tres contadores de morosidad entre sí, o la edad con el número de líneas). Para calcular la PDP se evalúa el modelo en **combinaciones de valores que casi no existen en la realidad**: por ejemplo, un cliente de 22 años con quince hipotecas. El modelo nunca vio nada parecido, así que su respuesta ahí es pura extrapolación y puede distorsionar la curva.

Los **ALE (Accumulated Local Effects)** corrigen el problema: en lugar de promediar sobre toda la población, dividen la variable en tramos pequeños y miden el efecto **solo sobre los clientes que realmente caen en cada tramo**, acumulando después esos efectos locales. Bajo correlación, ALE es la lectura correcta.

En la práctica se implementó el ALE **a mano**, sin librerías externas. Que las curvas ALE confirmen las formas que ya mostraba la PDP es un buen resultado: significa que la correlación no estaba distorsionando las conclusiones.

6.7 Técnica 7: LIME, la segunda opinión local

LIME explica una predicción concreta de una forma distinta a SHAP: **perturba ligeramente los datos del cliente** muchas veces, observa cómo responde el modelo, y ajusta un **modelo lineal sencillo** que imite ese comportamiento **en el entorno inmediato** de ese cliente. La idea es que aunque el modelo sea muy complejo globalmente, en un vecindario pequeño se parece a una recta.

	SHAP	LIME
Fundamento	Teoría de juegos (valores de Shapley)	Aproximación lineal local
Garantías	Sólidas: las contribuciones suman la predicción	Ninguna garantía formal
Estabilidad	Alta (determinista en árboles)	Menor: depende del muestreo aleatorio
Coste	Mayor	Menor
Intuición	Menos inmediata	Más intuitiva

Por qué se usaron los dos: si dos métodos con fundamentos tan distintos señalan **los mismos** factores como determinantes, la explicación es robusta y no un artefacto del método. En el cliente denegado analizado, LIME destaca el total de retrasos y la utilización del crédito, **que son justo las variables que domina SHAP**. La coincidencia refuerza la confianza en lo que se le contaría al cliente.

6.8 Resumen: qué aporta cada técnica

Técnica	Alcance	Pregunta que responde
Modelo surrogado	Global	¿Cuál es la política del modelo, en reglas legibles?
SHAP global	Global	¿Qué variables mandan y en qué dirección?
SHAP local	Local	¿Por qué este cliente concreto?
Contrafactuales	Local	¿Qué tendría que cambiar para que le concedieran?
Importancia por permutación	Global	¿Qué variables importan de verdad sobre datos nuevos?
PDP	Global	¿Qué forma tiene el efecto de cada variable?
ALE	Global	Lo mismo, pero sin distorsión por correlación
LIME	Local	Segunda opinión independiente sobre un caso

El argumento central de la auditoría

Las técnicas **convergen**: todas señalan la utilización de las líneas de crédito y el historial de morosidad como los ejes de la decisión, con efectos no lineales de tipo umbral.

Esa convergencia es el resultado más sólido de la práctica. Ninguna técnica aislada bastaría como auditoría —cada una tiene sus puntos ciegos—, pero que ocho enfoques distintos cuenten la misma historia hace muy improbable que las conclusiones sean un artefacto metodológico.

6.9 Qué se le dice a un cliente al que se le deniega el crédito

Esta pregunta la plantea el enunciado de forma explícita. La respuesta construida integra las técnicas anteriores en tres capas, y se implementó un **generador automático del informe**:

- Los motivos concretos** (de SHAP local): las dos o tres variables que más empujaron su score, traducidas a lenguaje llano. No 'su SHAP de RevolvingUtilization es 0,23', sino 'el nivel de utilización de sus tarjetas es muy elevado'.
- Qué está en su mano cambiar** (de los contrafactuales): objetivos alcanzables sobre variables accionables, del tipo 'si redujera el saldo dispuesto de sus tarjetas, la solicitud sería aprobada con los criterios actuales'.
- La garantía de trato uniforme** (de las reglas del surrogado): que se aplican los mismos criterios objetivos a todas las solicitudes, y que existe derecho a revisión por un analista.

Y qué NO se le comunica, deliberadamente:

- **Ni el score exacto ni el umbral interno.** Revelarlos permitiría hacer ingeniería inversa del sistema y manipularlo (por ejemplo, ajustar los datos justo por encima del corte).
- **Ni las variables no accionables como la edad.** Aunque el modelo las use, decirle a alguien que se le deniega por su edad no es una explicación aceptable, y abre el problema ético que se trata en la parte 10.

Parte 7. El enfoque alternativo: Multiarmed Bandit

El enunciado permitía enfocar el problema como modelo supervisado o como **Multiarmed Bandit**. Se hicieron ambos: el supervisado como solución principal y el bandit como comparación, siguiendo la línea del notebook de clase.

7.1 La diferencia de fondo

El modelo supervisado **ve todo el histórico etiquetado de golpe** y aprende de él. El bandit aprende **en marcha**: para cada cliente que llega elige una acción (conceder o denegar), recibe un premio o castigo según cómo salga, y actualiza su política. Nunca ve las respuestas correctas de antemano: solo aprende de las consecuencias de lo que hizo.

Aquí hay un matiz que es la esencia del aprendizaje por refuerzo: el bandit **solo aprende de la acción que tomó**. Si deniega un crédito, jamás sabrá si aquel cliente habría pagado. Esa información se pierde para siempre, y es una desventaja estructural frente al supervisado.

7.2 Exploración frente a explotación, y Thompson Sampling

Todo sistema que aprende de sus propias decisiones se enfrenta al mismo dilema: **explotar** lo que ya parece funcionar, o **explorar** alternativas por si fueran mejores. Si solo explota, puede quedarse anclado en una política mediocre por no haber probado nada más.

Se implementó **Thompson Sampling lineal** a mano. Para cada acción se mantiene una regresión bayesiana del premio esperado; en cada paso se **muestrea** de esa distribución y se ejecuta la acción con el mejor muestreo. La gracia del método es que la exploración sale gratis: cuando el modelo tiene poca información sobre una acción, su distribución es ancha y a veces sale elegida; a medida que acumula evidencia, las distribuciones se estrechan y converge a la mejor política.

7.3 Resultados y cómo interpretarlos

Política	Coste escenario 2	Lectura
Gradient Boosting + umbral óptimo	0,331	El mejor: ve todo el histórico y es no lineal
Bandit lineal (Thompson Sampling)	0,334	Muy cerca, pese a jugar con mucha desventaja
Conceder a todos	0,67 aprox.	Política trivial: se comen todos los impagos
Denegar a todos	0,93 aprox.	Política trivial: se pierde toda la cartera buena

Interpretación correcta: el supervisado gana (0,331 frente a 0,334), como era de esperar, porque dispone de todo el histórico etiquetado y de un modelo no lineal, mientras que el bandit aprende de refuerzos parciales con una política lineal. Pero la diferencia es **muy pequeña**, y el bandit supera con claridad a las políticas triviales, lo que demuestra que aprendió algo real.

Cuándo tendría sentido usar el bandit de verdad: en un sistema que arranca **sin histórico** y debe aprender sobre la marcha pagando el coste de sus propios errores. Ahí el supervisado ni siquiera podría entrenarse. Además, el bandit resuelve por diseño el problema del sesgo de selección que se comenta en la parte 8.10, porque su exploración le lleva a conceder de vez en cuando a perfiles que habría rechazado, generando así los datos que le faltan.

Parte 8. Las extensiones y mejoras (capítulo 11 del notebook)

El capítulo 11 recoge las mejoras sobre la solución base, divididas según a qué mitad de la evaluación contribuyen: bajar el coste (50% de la nota) y reforzar el análisis (el otro 50%).

Bloque A. Bajar el coste

8.1 Ingeniería de variables

Se crearon cuatro variables derivadas que codifican explícitamente relaciones que el modelo tendría que reconstruir por su cuenta:

Variable	Cálculo	Qué captura
TotalRetrasos	Suma de los 3 contadores de morosidad	Severidad global del historial en un solo número
IngresoPorDependiente	Ingreso / (dependientes + 1)	Renta realmente disponible por persona
DeudaMensualAbs	DebtRatio x MonthlyIncome	Deuda en euros: un 40% no es igual con sueldo alto que bajo
RatioLineasInmob	Hipotecas / total de líneas	Distingue deuda con activo detrás del consumo puro

8.2 Comparación de algoritmos

Se compararon HistGradientBoosting, LightGBM, XGBoost y CatBoost por AUC en validación cruzada. Las diferencias resultaron **pequeñas** (del orden de milésimas de AUC). La conclusión honesta es que en este problema **el algoritmo concreto importa poco**: lo que mueve el coste es el umbral y la cantidad de datos, no cambiar de librería de boosting.

8.3 La lección de la calibración (*sample_weight*)

Un resultado que parece un error y no lo es

Al ponderar la clase minoritaria con *sample_weight*, el coste del escenario 2 **se dispara** (pasa de 0,33 a 0,75 aprox.). No es un fallo del código.

El motivo es que ponderar **descalibra el modelo**: al darle más peso a los impagos, el modelo infla sistemáticamente las probabilidades que predice. Y entonces el umbral 0,090 —que se calculó para el modelo **sin** pesos— deja de tener sentido, porque ahora muchísimos más clientes lo superan, y se deniega masivamente.

La lección: *sample_weight* y umbral por coste son estrategias **alternativas, no acumulables**. Si se usa la primera hay que recalcular el umbral para ese modelo concreto. En un modelo ya bien calibrado, mover el umbral es la vía limpia.

8.4 Umbral por validación cruzada repetida, y la lección del optimismo

El umbral del capítulo 7 se calculó sobre **una sola** partición de validación. Para hacerlo más robusto se recalculó partiendo el entrenamiento en 5 pliegues repetidos 3 veces, obteniendo el umbral óptimo en cada uno de los 15 y promediando. Resultado: **0,090 con una desviación de 0,013** en el escenario 2, prácticamente idéntico al teórico (0,091), lo que confirma una vez más la buena calibración.

Otro resultado que despista y conviene saber explicar

En la tabla comparativa, la línea base con el umbral de un solo split aparece con un coste **ligeramente menor** que la misma configuración con el umbral por validación cruzada. Parece que la mejora empeora las cosas.

No es así: aquel umbral **se optimizó sobre esa misma muestra de validación**, así que juega con ventaja en el único sitio donde se le mide. Es un caso de libro de **métrica optimista**: cualquier parámetro ajustado sobre unos datos se ve mejor de lo que es sobre esos mismos datos. El umbral por CV, calculado sin mirar la validación, es el que mejor se comportará sobre clientes nuevos, que es lo único que importa en producción.

8.5 Reentrenar sobre todo el histórico: la mejora más rentable

Una vez fijado el umbral, ya no hay ninguna razón para seguir dejando fuera el 20% reservado a validación. El modelo final se reentrena sobre **las 105.000 filas completas**. Más datos significan una mejor ordenación del riesgo y, por tanto, menos falsos negativos en producción.

Es la mejora con mejor relación entre beneficio y esfuerzo de todas: es prácticamente gratis y es práctica estándar en la industria, una vez que la validación ya ha cumplido su función de fijar hiperparámetros y umbral.

Bloque B. Reforzar el análisis

8.6 Equidad (fairness) por edad

El modelo usa la edad y eso plantea un problema de discriminación. Se pasó de **mencionarlo a medirlo**: se calculó la tasa de denegación por tramo de edad y se comparó el modelo con edad frente a un modelo reentrenado sin ella.

Resultado e interpretación: retirar la edad **apenas cambia el coste global**, porque el modelo recupera buena parte de esa señal a través de variables correlacionadas (el historial, el número de líneas). Pero **sí redistribuye las denegaciones**: sin la edad, los solicitantes jóvenes son denegados algo menos y los mayores algo más.

La conclusión, que es fina y conviene saber defender, es que **el dilema no es de rendimiento sino de equidad**. No hay que elegir entre un modelo justo y un modelo rentable: se puede quitar la edad casi sin coste. La pregunta pasa a ser normativa, no técnica.

8.7 Intervalo de confianza del coste (bootstrap)

Decir 'el coste es 0,331' esconde que se trata de una **estimación sobre una muestra concreta**. Con **bootstrap** —remuestrear la validación con reemplazo miles de veces y recalculando el coste en cada réplica— se obtiene un intervalo de confianza del 95%: aproximadamente **[0,308 , 0,346]** en el escenario 2.

Cómo interpretarlo: el coste real en producción estará razonablemente dentro de ese rango. Y una consecuencia importante: **dos modelos cuyos costes difieran en menos que la amplitud del intervalo no son distinguibles** estadísticamente. Eso pone en su sitio las mejoras de milésimas del bloque A y es señal de madurez analítica reconocerlo.

8.8, 8.9 y 8.10: ALE, LIME y reject inference

ALE y LIME ya se explicaron en la parte 6 (secciones 6.6 y 6.7). Queda el **sesgo de selección**, que es el problema más profundo de todo el planteamiento:

Sesgo de selección y reject inference

El histórico solo contiene clientes **a los que en su día se les concedió** crédito. De los que fueron rechazados nunca se supo si habrían pagado. El modelo aprende, por tanto, sobre una población **filtrada**, pero en producción debe decidir sobre **todos** los solicitantes, incluidos perfiles parecidos a los que antaño se rechazaban.

Como el fichero no trae rechazados, se **simuló** el mecanismo: se consideró 'aceptado' al 80% de menor riesgo, se entrenó un modelo solo con ellos y se midió cuánto se degradaba frente al modelo entrenado con todos. **La degradación es notable (del orden de 0,06 de AUC)**, lo que demuestra que el problema es real y no teórico.

Después se aplicó *reject inference* por *parceling* (inferir una etiqueta probabilística para los rechazados y reentrenar). **Recupera poco** (del orden de 0,008 de AUC), y eso es un resultado honesto y coherente con la literatura: la técnica no crea información de la nada. **La única solución real es operativa**: conceder crédito a una pequeña muestra aleatoria de rechazados para poder observar qué hacen. Exactamente lo que un bandit haría por diseño al explorar.

Parte 9. Resultados: qué significa cada número

Resultado	Valor	Cómo interpretarlo
AUC del modelo	0,870	En el 87% de las parejas (un impago, un pagador) ordena bien. Buen nivel para scoring
AUC de la logística	0,854	El listón mínimo. La diferencia justifica usar un modelo complejo
PSI construcción vs producción	0,0005 aprox.	Muy por debajo de 0,10: misma población, el coste es extrapolable
Umbral escenario 1	0,545	Cerca del teórico 0,5. Se deniega poco (1,76%)
Umbral escenario 2	0,090	Casi idéntico al teórico 0,091: prueba de buena calibración
Coste escenario 1	0,062	Coste medio por cliente. No comparable con el del escenario 2
Coste escenario 2	0,331	Mayor porque el escenario penaliza 10 veces más, no porque el modelo sea peor
IC 95% del coste (esc. 2)	[0,308 , 0,346]	Rango realista. Diferencias menores que esto no son significativas
% denegados escenario 2	18,9%	Casi 1 de cada 5. Política conservadora, coherente con FN=10
Fidelidad del surrogado	94% / 99%	Las reglas simples reproducen casi toda la política del modelo
Coste del bandit (esc. 2)	0,334	Muy cerca del supervisado pese a aprender con información parcial
Degradación por sesgo selección	0,06 de AUC	El sesgo de selección es real y medible, no teórico

Los cuatro mensajes que resumen la práctica

1. Modelo y decisión son separables: un mismo modelo sirve para los dos escenarios cambiando solo el umbral.
2. La calibración es la pieza que sostiene todo: gracias a ella el umbral teórico y el empírico coinciden.
3. La auditoría es creíble porque **ocho técnicas distintas convergen** en la misma explicación.
4. Los límites (edad, sesgo de selección, incertidumbre del coste) están **medidos**, no solo mencionados.

Parte 10. Límites, ética y crítica

10.1 El uso de la edad

El modelo usa la edad y eso mejora ligeramente su capacidad predictiva. Pero condicionar el acceso al crédito a la edad es **discriminación estadística**: puede ser eficiente y a la vez injusto. Como se vio en 8.6, retirarla apenas cuesta rendimiento, así que **la decisión de mantenerla o no es normativa, no técnica**. En muchos marcos regulatorios habría que eliminarla o auditar formalmente su impacto.

10.2 El sesgo de selección

Ya tratado en 8.10. Es el límite más serio: el modelo no sabe qué habría pasado con los clientes que el banco venía rechazando, y sin embargo tiene que decidir sobre ellos.

10.3 Las etiquetas describen un periodo concreto

El histórico refleja un contexto económico determinado. Un cambio de ciclo (subida de tipos, recesión) alteraría las relaciones aprendidas. Por eso el PSI no debe calcularse solo una vez, sino **monitorizarse de forma continua** en producción para detectar cuándo el modelo empieza a quedarse obsoleto.

10.4 El coste es una esperanza estadística

El 0,331 es un valor esperado, no una garantía. El coste real fluctuará a su alrededor, dentro del intervalo de confianza calculado.

10.5 Qué se haría con más tiempo

- Reservar un **tercer conjunto de test** para eliminar el pequeño optimismo de elegir configuración sobre validación.
- Un análisis de **fairness más completo**, con métricas formales (paridad demográfica, igualdad de oportunidades) y sobre más atributos, no solo la edad.
- Un **plan de monitorización** en producción: PSI continuo, alertas de deriva y reentrenamiento periódico.
- Una política de **exploración controlada** (conceder a una muestra aleatoria de rechazados) para atacar de raíz el sesgo de selección.

Parte 11. Preguntas de defensa y cómo responderlas

¿Por qué el coste del escenario 2 es mucho mayor? ¿El modelo funciona peor?

No. Es el mismo modelo con distinto umbral. El escenario 2 **penaliza cada falso negativo diez veces más**, así que la escala del coste es otra. Los costes de los dos escenarios no son comparables entre sí; solo tiene sentido comparar políticas **dentro** de un mismo escenario.

¿Por qué no se entrenó un modelo distinto para cada escenario?

Porque no hace falta y sería peor. El modelo estima una **probabilidad de impago**, que es la misma con independencia de lo que cueste cada error. Lo que cambia con los costes es **dónde se corta** esa probabilidad. Entrenar dos modelos añadiría complejidad sin ganancia, y de hecho el experimento con *sample_weight* muestra que meter los costes dentro del entrenamiento descalibra y empeora.

¿Por qué no se eliminaron las filas con datos ausentes?

Por dos razones. Primera, en producción hay que decidir sobre los 45.000 clientes y no se puede descartar a nadie. Segunda, se comprobó que la ausencia de ingreso **es informativa** (esos clientes impagan menos: 5,5% frente a 7,0%), así que eliminarlos o rellenar el hueco con la media destruiría señal útil. Se conserva con una variable indicadora y el modelo gestiona los huecos de forma nativa.

¿Cómo se sabe que las explicaciones son correctas y no una historia bonita?

Por **convergencia**: se aplicaron ocho técnicas con fundamentos distintos (reglas, teoría de juegos, perturbación local, permutación, efectos acumulados) y todas señalan las mismas variables dominantes. Además el surrogado tiene una **fidelidad del 94%**, es decir, reproduce casi toda la política real del modelo. Si las conclusiones fueran un artefacto de un método, las demás no coincidirían.

¿Por qué SHAP y no solo la importancia de variables del propio modelo?

La importancia interna de un árbol mide cuánto se usó una variable para partir, que no es lo mismo que cuánto influyó en la decisión, y tiende a favorecer variables con muchos valores distintos. SHAP reparte la predicción con **garantías matemáticas** (las contribuciones suman exactamente la predicción) y además da explicación **por cliente**, que es lo que se necesita para justificar una denegación concreta.

¿Qué pasa si un cliente pide explicaciones?

Se le entrega un informe con tres capas: los motivos concretos de su caso (SHAP local traducido a lenguaje llano), las acciones realistas que revertirían la decisión (contrafactuales restringidos a variables accionables y verificados contra el umbral real) y la garantía de trato uniforme (reglas del surrogado), más el derecho a revisión humana. No se le revela el score ni el umbral, para evitar ingeniería inversa del sistema.

¿El modelo discrimina por edad?

Usa la edad, y la tasa de denegación cae de forma marcada con ella. Se midió el efecto: quitar la edad **apenas cambia el coste global** pero **redistribuye** las denegaciones entre tramos. Por tanto es perfectamente viable prescindir de ella, y mantenerla o no es una decisión normativa más que técnica. Es un problema que la práctica **mide**, no solo menciona.

¿Por qué el bandit pierde contra el supervisado? ¿Estaba mal implementado?

No: pierde por diseño y por muy poco (0,334 frente a 0,331). El supervisado **ve todas las etiquetas del histórico desde el primer momento**, mientras que el bandit solo aprende de las consecuencias de las acciones que toma —si deniega, nunca sabrá si aquel cliente habría pagado— y además usa una política lineal. Su valor está en el escenario para el que se diseñó: sistemas sin histórico previo que aprenden en marcha.

¿Se puede confiar en que el coste de validación se repita en producción?

Sí, con dos avales. El **PSI** (del orden de 0,0005) demuestra que construcción y producción son la misma población. Y el **intervalo de confianza bootstrap** cuantifica cuánto puede oscilar el valor. Además, el modelo entregado se reentrenó sobre el histórico completo, así que dispone de más datos que el evaluado y su coste esperado es igual o menor.

¿Cuál es la mayor debilidad del trabajo?

El **sesgo de selección**: el histórico solo contiene créditos concedidos, así que el modelo nunca ha visto qué pasa con los perfiles que el banco venía rechazando. Se cuantificó mediante simulación (una degradación del orden de 0,06 de AUC) y se comprobó que el *reject inference* recupera poco. La solución real es operativa: conceder a una muestra aleatoria de rechazados para observar qué ocurre.

Parte 12. Glosario

Término	Definición en una línea
ALE	Efectos acumulados locales: como la PDP pero sin distorsión cuando hay variables correlacionadas
AP	Precisión media: resume la curva Precision-Recall en un número
AUC	Probabilidad de que el modelo puntúe con más riesgo a un impago que a un pagador
Bandit contextual	Sistema que aprende en marcha eligiendo acciones y observando el premio obtenido
Bootstrap	Remuestrear los datos con reemplazo para estimar la incertidumbre de una métrica
Calibración	Que una probabilidad predicha del 30% se corresponda con un 30% real de impagos
Capado / winsorización	Recortar los valores extremos a un percentil para limitar su influencia
Contrafactual	Cambio mínimo en los datos de un cliente que invertiría la decisión del modelo
Falso negativo (FN)	Conceder crédito a quien impaga: se pierde el capital
Falso positivo (FP)	Denegar crédito a quien habría pagado: se pierde un buen cliente
Fidelidad	Porcentaje de decisiones del modelo original que el surrogado reproduce
Fuga de información	Usar en el entrenamiento información que no estaría disponible al predecir
Gradient Boosting	Muchos árboles pequeños encadenados, cada uno corrigiendo los errores del anterior
LIME	Explica una predicción ajustando un modelo lineal simple en el entorno de ese cliente
Lift	Cuántas veces más impagos hay en un grupo respecto a la media
PDP	Dependencia parcial: efecto medio de una variable sobre la probabilidad predicha
PSI	Índice que mide si dos poblaciones (construcción y producción) se parecen
Recall	De todos los impagos reales, qué porcentaje detecta el modelo
Reject inference	Técnicas para corregir que el histórico solo contenga créditos concedidos
sample_weight	Dar más peso a la clase minoritaria durante el entrenamiento
SHAP	Reparto justo (teoría de juegos) de la predicción entre las variables
Surrogado	Modelo simple entrenado para imitar a un modelo complejo y hacerlo legible
Thompson Sampling	Estrategia de bandit que explora muestreando de la incertidumbre de cada acción
Umbral	Punto de corte de la probabilidad a partir del cual se deniega el crédito

Actualizacion - Nuevas mejoras (revision ampliada)

Que es esta actualizacion

Estas paginas amplian la **Parte 8** (extensiones del capitulo 11 del notebook) con **cinco mejoras** anadidas en una revision posterior. Cada una se situa en su bloque: las que bajan el coste (Bloque A) y las que refuerzan el analisis (Bloque B).

El notebook completo se ejecuta de principio a fin sin errores tras estos cambios, y los ficheros de produccion se regeneran con el modelo final reentrenado sobre todo el historico.

A.1 Restricciones de monotonia (Bloque A, notebook 11.2.1)

En riesgo de credito hay relaciones cuyo **sentido se conoce de antemano** y no deberia invertirse por ruido muestral: a mas morosidad, mas riesgo; a mas edad o mas ingreso, menos. **HistGradientBoostingClassifier** permite imponer esas restricciones de monotonia, forzando que la probabilidad de impago sea no decreciente (o no creciente) en la variable indicada.

Sentido forzado sobre el riesgo	Variables
Mas valor -> MAS riesgo (+1)	Utilizacion del credito, los 3 contadores de morosidad, TotalRetrasos,CodigoMoraEspecial y DebtRatio
Mas valor -> MENOS riesgo (-1)	Edad, MonthlyIncome, IngresoPorDependiente
Sin restriccion (0)	Numero de lineas, dependientes y flags de sentido ambiguo

Aporta en los **dos frentes de la nota** a la vez: como coste, regulariza con conocimiento de dominio (la AUC se mantiene, 0.870 sin restricciones frente a 0.869 con ellas, y el coste apenas cambia); y como analisis, hace el modelo **mucho mas defendible ante un regulador** ('el sistema nunca penaliza tener menos deuda o mas ingreso') y elimina los tramos no monotonos que enturbian las curvas PDP/ALE. Entra como una candidata mas en la seleccion final (11.5).

A.2 Test de DeLong: si las diferencias de AUC son reales o ruido (Bloque A, 11.2.2)

La comparacion de algoritmos (8.2) y la superioridad del boosting sobre la logistica se apoyan en diferencias de AUC a veces muy pequenas. El **test de DeLong** pone un **p-valor** a esas diferencias, comparando dos AUC sobre la misma validacion y teniendo en cuenta la correlacion entre ambas curvas ROC. Se implemento a mano (Sun y Xu, 2014), sin librerias externas.

Comparacion (A vs B)	dif AUC	p-valor	Significativa
Gradient Boosting vs Regresion logistica	+0.015	~ 1e-14	SI
HistGB base vs mejor boosting alternativo (CatBoost)	-0.001	0.40	NO

Lectura: la ventaja del modelo no lineal sobre la logistica es **estadisticamente solida**, pero la ventaja del mejor algoritmo alternativo **no es significativa** ($p = 0.40$). Es la confirmacion numerica de la conclusion de 8.2: en este problema el algoritmo concreto importa poco, y no compensa complicar el modelo por una milésima de AUC que cabe dentro del ruido. Con ~21.000 filas de validacion el test tiene mucha potencia, asi que la lectura correcta combina **significancia** (es real?) y **magnitud** (compensa?).

A.3 Calibracion explicita: el rescate de sample_weight (amplia 8.3, 11.3.1)

La seccion 8.3 explicaba que ponderar la clase minoritaria con **sample_weight** descalibra el modelo y dispara el coste. Aqui se **cuantifica** la calibracion (con el **Brier score** y el **ECE**, Expected Calibration Error) y se cierra el cabo suelto: una **recalibracion isotonica** devuelve el modelo ponderado a un estado en que el umbral vuelve a ser valido. La clave tecnica es calibrar sobre un conjunto **sin pesos** (con `cv='prefit'`); si se calibra con

los pesos, no se arregla nada.

Variante	Brier	ECE	Coste E2	AUC
Base (sin recalibrar)	0.049	0.005	0.33	0.870
Base recalibrado	0.049	0.004	0.33	0.869
sample_weight (sin recalibrar)	0.139	0.246	0.75	0.869
sample_weight recalibrado	0.049	0.002	0.33	0.869

La leccion, ahora demostrada

El modelo base ya esta bien calibrado (ECE 0.005), asi que recalibrarlo apenas lo cambia. El modelo con **sample_weight** esta muy descalibrado (ECE 0.246) y su coste se dispara a 0.75; tras recalibrar, su ECE baja a 0.002 y su coste vuelve a 0.33, con la AUC intacta.

Confirma que **sample_weight y umbral por coste son alternativas, no acumulables**: la ponderacion no es mala, solo cambia la escala de la probabilidad, y una vez recalibrada vuelve a ser utilizable. Para el modelo de produccion, que parte ya calibrado, la recalibracion es innecesaria.

A.4 El mejor algoritmo entra en la seleccion final (amplia 8.2 y 8.5, 11.5)

La seleccion final ya no clona siempre el HistGradientBoosting: ahora compara de forma homogenea, sobre la validacion intacta y con el umbral robusto, todas las candidatas (variables derivadas, monotonia, ponderacion y el **mejor algoritmo de 8.2**) y **reentrena la ganadora sobre las 105.000 filas completas**. Asi, la decision de que algoritmo llega a produccion se toma por su coste medido, no por intuicion. Coherente con A.2, la ganadora suele ser la configuracion base: el cambio de algoritmo no reduce el coste de forma significativa.

B.1 Equidad por edad con metricas formales (amplia 8.6, 11.6)

La seccion 8.6 media la tasa de denegacion por tramo de edad. Aqui se anaden las **metricas formales** que se usan en auditoria de credito, comparando el modelo con y sin la variable edad (politica del escenario 2):

Metrica de equidad (escenario 2)	Con edad	Sin edad
Disparate Impact (regla del 80 %: debe ser 0.80 o mas)	0.67	0.76
Demographic Parity difference (menor = mas justo)	0.32	0.22
Equal Opportunity difference (menor = mas justo)	0.35	0.27
FPR gap: buenos clientes denegados (menor = mas justo)	0.27	0.18

Lectura: con la edad, el **Disparate Impact es 0.67**, por debajo del umbral legal de 0.80: hay indicio de **impacto adverso**. El contraste por tramos es crudo - entre los solicitantes de 20-30 anos se deniega al 31 % de los **buenos pagadores**, frente al 4 % de los mayores de 70. Retirar la edad sube el DI a 0.76 y reparte las denegaciones de forma mas uniforme, **apenas sin coste global**. Confirma la conclusion de 8.6: el dilema es **normativo, no de rendimiento**. Esto convierte en realizado el punto de 'que se haria con mas tiempo' (10.5) sobre fairness con metricas formales.

Glosario: terminos nuevos

Termino	Definicion en una linea
Test de DeLong	Contraste que dice si la diferencia de AUC entre dos modelos es real o ruido muestral
Monotonia (monotonic_cst)	Restriccion que obliga a que el efecto de una variable sobre el riesgo tenga siempre el mismo sentido
Disparate Impact	Cociente entre la tasa de aprobacion del grupo menos y mas favorecido; por debajo de 0.80 indica discriminacion

Termino	Definicion en una linea
ECE	Expected Calibration Error: error medio entre la probabilidad predicha y la frecuencia real de impago
Brier score	Error cuadratico medio de las probabilidades; resume calibracion y discriminacion en un numero

Preguntas de defensa adicionales

La ventaja del boosting sobre la logistica, es significativa? Y la del mejor algoritmo?

La del boosting sobre la logistica si (test de DeLong, p del orden de $1e-14$). La del mejor algoritmo alternativo **no** es significativa ($p = 0.40$): por eso no se complica el modelo por ella y la configuracion base es una eleccion defendible.

Dijiste que `sample_weight` empeora el coste. Entonces no sirve?

Sirve, pero **descalibra** el modelo, y por eso el umbral calculado para el modelo sin pesos deja de valer. Con una recalibracion isotonica el ECE vuelve a 0.002 y el coste a 0.33. Son estrategias alternativas: o se pondera y se recalibra, o se deja el modelo base ya calibrado y se mueve solo el umbral.

Medis la equidad con metricas formales o solo tasas de denegacion?

Con metricas formales: Disparate Impact (regla del 80 %), paridad demografica, igualdad de oportunidades y FPR gap, comparando el modelo con y sin la edad. El modelo con edad incumple la regla del 80 % (DI 0.67).